

## Zajęcia 3. Gromadzenie i analiza wymagań

Wymagania funkcjonalne (co system ma robić?):

1. Sprawdzenie hasła przy logowaniu się użytkownika
2. Np. kalkulator powinien liczyć wynik podanej przez użytkownika równości

Wymagania niefunkcjonalne (jak system ma działać?):

1. Optymalizacja (jak system dobrze i "płynnie" działa pod wpływem różnej ilości jednocześnie pracujących "aplikacji" pobocznych)
2. Dostęp do internetu (czy system może działać bez internetu lub na stałe musi być podłączony do niego)

## Zajęcia 4. Gromadzenie i analiza wymagań

Wymagania funkcjonalne:

1. System ma umożliwiać analizę sentymentu przy użyciu różnych słowników sentymentu (np. NRC, Bing, Loughran, Afinn).
2. System ma prezentować wyniki analizy sentymentu w formie wykresów, ilustrując liczbę słów wg poszczególnych sentymentów.

Wymagania niefunkcjonalne:

1. Proces analizy sentymentu powinien działać w czasie krótszym niż 5 sekund dla tekstu do 10 000 słów.
2. Kod powinien być poprawnie napisany, a komentarze w kodzie powinny wyjaśniać najważniejsze operacje, aby ułatwić jego konserwację i ewentualną modyfikację.

## Zajęcia 5. Dokumentacja i specyfikacja wymagań

1. Użytkownik - ma jasno określone funkcje systemu, więc wie, czego się spodziewać i jak z niego korzystać.
2. Programista - ma precyzyjne wymagania, więc będzie mu łatwiej implementować system bez zgadywania.
3. Kierownik projektu - może lepiej planować czas i zasoby, co zmniejsza ryzyko opóźnień.

## Zajęcia 6. Dokumentacja i specyfikacja wymagań

Scenariusz 4. Wczesne wykrywanie ryzyk reputacyjnych na podstawie analizy sentymentu opinii klientów z formularzy kontaktowych

Jako: Analityk danych w dziale Customer Experience

Chcę: Automatycznie analizować opinie klientów pochodzące z formularzy kontaktowych pod kątem sentymentu oraz wykrywać potencjalne sygnały negatywnych doświadczeń

Aby: Wcześniej identyfikować ryzyka reputacyjne i umożliwić szybką reakcję na problemy klientów, zanim wpłyną one na wizerunek marki

Kryteria akceptacji:

1. Użytkownik może wczytać dane tekstowe z formularzy kontaktowych (np. plik .txt lub .csv)
2. Skrypt przeprowadza analizę sentymentu za pomocą różnych słowników
3. Skrypt identyfikuje i oznacza wypowiedzi o silnie negatywnym sentymencie jako potencjalne ryzyko reputacyjne
4. Skrypt generuje wykresy skumulowanego sentymentu oraz jego zmian w czasie
5. Skrypt umożliwia filtrowanie i przeglądanie najbardziej negatywnych opinii
6. Skrypt może generować alerty (np. przekroczenie progu negatywnego sentymentu)
7. Użytkownik może identyfikować kluczowe problemy klientów i podejmować działania naprawcze

## Zajęcia 7. Reproducible research

1. *Opis projektu* (np. README w repozytorium na GitHub) – zawiera cel projektu, zakres analizy oraz opis wyników.
2. *Dane wejściowe* – źródło danych, sposób ich pozyskania oraz format.
3. *Kod źródłowy* – kompletny, czytelny i umożliwiający wykonanie całej analizy.
4. *Środowisko pracy* – informacje o użytych narzędziach, bibliotekach oraz ich wersjach.
5. *Dokumentacja procesu* – opis kroków analizy, zastosowanych metod i założeń.
6. *Raport reprodukowalny* – dokument integrujący kod, wyniki i opis (np. Jupyter Notebook, R Markdown).
7. *Instrukcja uruchomienia* – opis kroków potrzebnych do uruchomienia projektu.
8. *Struktura projektu* – organizacja plików i katalogów.
9. *Wersjonowanie* – kontrola zmian w projekcie (np. przy użyciu systemu Git).

## Zajęcia 8. Reproducible research

Narzędzia wspierające podejście *Reproducible research*, których używam:

1. Jupyter Notebook
2. GitHub
3. Git

4. Markdown
5. Biblioteki w Pythonie (np. matplotlib, pandas)
6. HTML

## Zajęcia 9. Metodyki Agile i Waterfall

Do realizacji nowoczesnych projektów systemów informatycznych wybrałbym metodykę Agile, ponieważ posiada ona następujące istotne zalety:

1. Elastyczność oraz możliwość szybkiego reagowania na zmiany w wymaganiach projektu.
2. Stały feedback od klienta, co przekłada się na lepsze dopasowanie produktu końcowego do jego oczekiwań.
3. Mniejsze ryzyko niepowodzenia projektu oraz możliwość szybszego osiągnięcia efektów biznesowych dzięki przyrostowemu dostarczaniu funkcjonalności.

## Zajęcia 10. Metodyki Agile i Waterfall\_cz2

Tablica Kanban dla projektu dotyczącego Topic Modellingu:

*To Do:*

1. Inżynieria cech (reprezentacja BoW, ewentualne TF-IDF)
2. Przygotowanie danych pod LDA (oczyszczenie DTM z pustych wierszy)
3. Modelowanie tematów (LDA dla różnych wartości k)
4. Interpretacja tematów (top słowa w tematach)
5. Wybór optymalnej liczby tematów

*In Build:*

1. Eksploracyjna analiza danych (EDA):
2. analiza częstości słów
3. identyfikacja najczęstszych słów
4. wizualizacja (np. wordcloud)

*Done:*

1. wczytanie danych
2. przygotowanie tekstu (czyszczenie, preprocessing)
3. utworzenie korpusu i macierzy DTM

## Zajęcia 11. Analiza ryzyka i macierz ryzyka

Krytyczne ryzyko związane z projektowaniem systemu IT - *pojawienie się błędów w kodzie, które nie zostaną od razu wykryte.*

Ocena:

*Prawdopodobieństwo:* wysokie

*Wpływ:* średni lub wysoki (zależy od błędu, bo on może być drobny, ale też może rozwalić całą funkcjonalność)

-> **Poziom ryzyka:** średnie lub wysokie

## Zajęcia 12. Podejście TFIDF w algorytmach data science

*Algorytmy, w których TF-IDF może poprawić wyniki:*

1. Klastrowanie k-means (bo redukuje wpływ bardzo częstych słów i lepiej uwidacznia różnice między dokumentami. Dzięki temu dokumenty o podobnej tematyce łatwiej trafiają do tego samego klastra).
2. Topic modelling (LDA) (bo TF-IDF może czasem pomóc we wstępnym oczyszczaniu danych, ale też ma swoje wady, o których napiszę w drugiej części).
3. Analiza sentymentu (bo przy podejściu opartym na cechach tekstowych TF-IDF może poprawić wyniki, bo wzmacnia bardziej charakterystyczne słowa opinii).

*Algorytmy, w których lepiej unikać TF-IDF:*

1. Asocjacje (bo TF-IDF zmienia oryginalne częstości słów, przez co może zniekształcić siłę korelacji między wyrazami).
2. Topic modelling (LDA) (bo TF-IDF może zaburzać probabilistyczną interpretację tematów).

## Zajęcia 13. Klasyfikacja

Najważniejsze metryki dla oceny modelu klasyfikacji:

1. Accuracy
  - Odsetek wszystkich poprawnie zaklasyfikowanych przypadków
2. Precision
  - Odpowiada na pytanie: "Spośród wszystkich przewidzianych „tak” — ile rzeczywiście było „tak”?"
3. Recall
  - Odpowiada na pytanie: "Spośród wszystkich rzeczywistych „tak” — ile model poprawnie wykrył?"
4. Specificity

- Odpowiada na pytanie: "Spośród wszystkich rzeczywistych „nie" — ile model poprawnie rozpoznał jako „nie"?"
- 5. NPV
  - Odpowiada na pytanie: "Spośród wszystkich przewidzianych „nie" — ile faktycznie było „nie"?"
- 6. F1 Score
  - Średnia harmoniczna Precision i Recall
- 7. AUC-ROC
  - Pole pod krzywą ROC (wykres TPR vs FPR dla różnych progów decyzyjnych)

## Zajęcia 14. Klasyfikacja c.d.

### **Random Forest:**

1. **Jak działa?:**
  - Random Forest buduje wiele niezależnych drzew decyzyjnych, a następnie łączy ich wyniki metodą głosowania większościowego (dla klasyfikacji).
2. **Dlaczego warto byłoby go przetestować w zadaniu klasyfikacji recenzji/opinii klientów:**
  - *Odporność na szum* (recenzje klientów często zawierają literówki, slang i t.d, z którymi system dobrze pracuje)
  - *Nieliniowość* (RF wychwytuje złożone, nieliniowe zależności między słowami/cechami)
  - *Ważność cech* (model zwraca ranking najważniejszych słów/fraz, co daje cenne informacje biznesowe (np. "cena", "dostawa" i t.d.)
  - *Odporność na przeuczenie* — averaging wielu drzew naturalnie redukuje overfitting
3. **Nowoczesne zastosowania:**
  - *E-commerce* (automatyczne tagowanie recenzji jako pozytywne/negatywne/neutralne)
  - *CRM / Customer Success* (priorytetyzacja zgłoszeń)
  - *Systemy rekomendacyjne* (filtrowanie produktów na podstawie sentymentu recenzji)
  - *Monitoring mediów* (klasyfikacja wzmianek o marce w czasie rzeczywistym)

### **Logistic Regression:**

1. **Jak działa?:**
  - Oblicza ważoną sumę cech wejściowych, a następnie przepuszcza wynik przez funkcję sigmoidalną (S-kształtna), która sprowadza wartość do przedziału (0, 1) — interpretowanego jako prawdopodobieństwo przynależności do klasy.

**2. Dlaczego warto byłoby go przetestować w zadaniu klasyfikacji recenzji/opinii klientów:**

- *Interpretowalność* (wagi modelu wprost wskazują, które słowa najbardziej "ciągną" ku pozytywnemu/negatywnemu sentymentowi)
- *Efektywność z TF-IDF* (świetnie współpracuje z klasyczną wektoryzacją tekstu; przy tysiącach cech (słów) nadal działa szybko)
- *Świetny baseline* (to punkt odniesienia, z którym porównuje się bardziej złożone modele)
- *Kalibrowane prawdopodobieństwa* (wynik 0.92 dla "negatywna" oznacza realną pewność modelu, co pozwala na progowanie)

**3. Nowoczesne zastosowania:**

- *Chatboty / voiceboty* (klasyfikacja intencji użytkownika w czasie rzeczywistym)
- *Systemy antyspamowe* (detekcja spamu jako klasyfikacja binarna)
- *Fintech / Bankowość* (klasyfikacja skarg klientów wg kategorii regulacyjnych)
- *Healthcare* (analiza opinii pacjentów w systemach NFZ lub prywatnych sieci medycznych)